

GP5

Автоматизация гистологического анализа препаратов рака молочной железы

Группа 7

Або Полина

Бурьянова Софья

Вохминцев Иван

Рыжов Кирилл

Июнь 2026



О проекте

Проблема — рак молочной железы наиболее распространенная форма рака у женщин во всем мире. Врачи тратят часы на рутинный просмотр сотен стекол, что повышает риск пропуска микроочагов опухоли, тогда как скорость и точность диагностики напрямую влияют на возможность спасти пациенток.

3 млн+

Миллиона женщин болеют раком молочной железы ежегодно

80%

Доживают до старости из-за диагностирования на поздних стадиях

50%

сокращения времени при диагностировании большого потока обращений пациентов

99%

Пятилетняя выживаемость женщин при раннем выявлении опухоли

Решение — Интеллектуальная система поддержки принятия врачебных решений (СППВР) для автоматизации анализа гистологических снимков пациентов

Бизнес-цели

В2В ценность



Бизнес-цель

Главная цель платформы
—помощь в процессе
диагностики за счет
объединения
человеческого опыта и
технологий deep learning



Сокращение времени анализа 1 кейса в 2–3 раза позволит клиникам обрабатывать большой поток пациентов без расширения штата, что позволит помочь большему количеству пациентов



Снижение процента ложноотрицательных диагнозов уменьшит судебные риски и расходы на повторные исследования



Уменьшение выгорания врачей за счет автоматизации рутинного поиска патологий. Врач фокусируется только на сложных, пограничных случаях




Статус технологичного медицинского центра, использующего передовые СППВР-технологии, повысит репутацию среди потенциальных пациентов

Часть 1

Диагностика на основе табличных данных





Снижение размерности

1 31 -> 20

сокращение количества признаков


2 До 0

снижение корреляции между компонентами

3 Результат

Уменьшение количества признаков -
> нейронная сеть будет работать быстрее

Нет сильно коррелирующих между собой признаков



Архитектура и обучение полносвязной нейронной сети

С оптимизатором SGD

Входной слой

20 Компонент, после PCA

linea

200 нейронов и функция активации ReLU

Скрытый слой 2

150 нейронов и функция активации ReLU

Выходной слой

2 нейрона для классификации доброкачественного и злокачественного образования

С оптимизатором ADAM

Входной слой

Компонент, после PCA

Скрытый слой 1

нейронов и функция активации ReLU

Скрытый слой 2


нейронов и функция активации ReLU

Выходной слой


нейрона для классификации доброкачественного и злокачественного образования

Архитектура и обучение полносвязной нейронной сети


SGD



Adam



Архитектура и обучение полносвязной нейронной сети




Сравнение метрик | test

2 слоя [200,150]

Функция активации: ReLU

Функция потерь: CrossEntropyLoss

Оптимизатор: SGD с $lr = 0,01$




2 слоя [200,150]

Функция активации: ReLU

Функция потерь: CrossEntropyLoss

Оптимизатор: Adam с $lr = 0,001$





3 слоя [150, 100, 50]

Функция активации: ReLU и Sigmoid

Функция потерь: BCELoss

Оптимизатор: Adam с $lr = 0,001$





Сравнение метрик | train

2 слоя [200,150]

Функция активации: ReLU

Функция потерь: CrossEntropyLoss

Оптимизатор: SGD с lr = 0,01




2 слоя [200,150]

Функция активации: ReLU

Функция потерь: CrossEntropyLoss

Оптимизатор: Adam с lr = 0,001




3 слоя [150, 100, 50]

Функция активации: ReLU и Sigmoid

Функция потерь: BCELoss

Оптимизатор: Adam с lr = 0,001



Оптимизация и результаты модели

Изменение архитектуры

- количество скрытых слоёв увеличено до трёх
- размерность слоёв: 150, 100 и 50 нейронов
- выходной слой сокращён до одного нейрона
- добавлена функция активации Sigmoid
- модель выдаёт вероятность принадлежности к злокачественному классу

1

Построили модель

Модель бинарной классификации по целевому признаку diagnosis

2

Определение образования

Научили модель определять тип образования на основе количественных характеристик клеточных ядер

3

Автоматизация мед данных

Подтвердили возможность автоматизации первичных медицинских данных и сформировали 1 уровень СППВР

97% – Accuracy

доля правильно классифицированных наблюдений

98% – Precision

доля действительно злокачественных случаев среди предсказанных моделью

95% – Recall

доля выявленных злокачественных образований

0,0635 – Test Loss

итоговая ошибка на тестовой выборке

Часть 2

Диагностика на основе табличных медицинских данных



О данных

Данные для анализа

Breast Histopathology Images

Датасет содержит 277 524 фрагмента гистологических изображений молочной железы, относящихся к разным пациентам.

Особенности данных


количество изображений на одного пациента различается, изображения распределены неравномерно

Целевая переменная

0 – участок ткани без признаков инвазивной протоковой карциномы
1 – участок ткани с признаками инвазивной протоковой карциномы.

Требования к трайн и тест

изображения одного пациента не должны одновременно попадать в обучающую и тестовую выборки



Подготовка данных

разбиение по пациентам с помощью StratifiedGroupKFold

сокращение выборки до 60 000 изображений для ускорения эксперимента

40 000

Изображений в трайн

10 000

Изображений в валидационной

10 000

В тестовой

изменение размера изображений до 96 × 96 пикселей



Архитектура и обучение моделей

Для классификации гистологических изображений были сравнены 3 предобученные сверточные нейронные сети:

1

ResNet50V2

глубокая архитектура с остаточными связями

2

MobileNetV2

облегченная архитектура с меньшими вычислительными затратами;



Показала лучшее качество среди: PR AUC – 0,8469 на валидационной выборке и 0,8366 на тестовой.

3

EfficientNetV2B0

архитектура, оптимизированная по качеству и эффективности.

Подбор гиперпараметров

- количество нейронов в полносвязном слое: 64, 128 или 256;
- Dropout: от 0,2 до 0,5 с шагом 0,1;
- скорость обучения: 0,001; 0,0003 или 0,0001;
- оптимизатор: Adam;
- функция потерь: Binary Crossentropy;
- основная метрика: PR AUC;
- подбор параметров: Random Search;
- количество попыток подбора: 3 trials, каждая конфигурация запускалась 2 раза;
- логирование экспериментов: Weights & Biases.

Общая схема модели

предобученная CNN-модель с весами ImageNet



Global Average Pooling



полносвязный слой с ReLU



Dropout



выходной слой с Sigmoid



вероятность наличия опухолевого участка


Результаты

Модель научилась присваивать каждому фрагменту изображения вероятность наличия опухолевого участка. Это позволяет использовать решение не только для бинарного ответа, но и для ранжирования изображений по уровню риска и выделения наиболее подозрительных участков для последующей проверки врачом

сравнения трёх моделей

Модель	Test PRAUC	Test Loss
ResNet50V2	0,7980	0,3668
MobileNetV2	0,8366	0,3276
EfficientNetV2B0	0,8345	0,3497

сравнение трёх моделей по лучшему значению PR AUC на валидационной выборке



Вывод

Модель способна различать фрагменты ткани по наличию опухолевых изменений и формировать количественную оценку риска для каждого изображения, что делает результаты анализа более структурированными и сопоставимыми